

# Ejercicios 1 a 3 hogg fitting

## Preparación previa

Primero vamos a preparar los datos para usarlos facilmente

```
library(MASS)
x <- c(201, 244, 47, 287, 203, 58, 210, 202, 198, 158, 165, 201, 157, 131, 166, 160, 186, 125, 218, 146)
y <- c(592, 401, 583, 402, 495, 173, 479, 504, 510, 416, 393, 442, 317, 311, 400, 337, 423, 334, 533, 344)
stdy <- c(61, 25, 38, 15, 21, 15, 27, 14, 30, 16, 14, 25, 52, 16, 34, 31, 42, 26, 16, 22)
stdx <- c(9, 4, 11, 7, 5, 9, 4, 4, 11, 7, 5, 5, 5, 6, 6, 5, 9, 8, 6, 5)
roxy <- c(-0.84, 0.31, 0.64, -0.27, -0.33, 0.67, -0.02, -0.05, -0.84, -0.69, 0.3, -0.46, -0.03, 0.5, 0.73, -0.52, 0.9, 0.6, 0.4, 0.2)

df <- data.frame(x, y, stdy, stdx, roxy)
df["varx"] <- stdx^2
df["vary"] <- stdy^2
df["rosd"] <- roxy*stdx*stdy
df["uncertxn"] <- x-stdx
df["uncertxp"] <- x+stdx
df["uncertyn"] <- y-stdy
df["uncertyp"] <- y+stdy
mstd1 <- diag(df[, "vary"])
mstd2 <- diag(df[5:20, "vary"])
```

## Ejercicio 1


En este ejercicio lo que se nos pide es que usemos regresion lineal simple para hacer algo similar a la figura 1 usando un modelo lineal tal que

$$y = mx + b$$

Para hallar los parámetros  $W_{ML}$  vamos a hacer lo siguiente

$$\begin{bmatrix} b \\ m \end{bmatrix} = [A^T C^{-1} A]^{-1} A^T C^{-1} Y$$

```
mx <- cbind(rep(1, 16), df[5:20, "x"]) # matriz de diseño
my <- matrix(df[5:20, "y"], ncol=1, nrow=16) # variable objetivo
model <- solve(t(mx) %*% solve(mstd2) %*% mx) %*% t(mx) %*% solve(mstd2) %*% my
predicty1 <- mx %*% model
plot(mx[, 2], my[, 1], xlim = c(0, max(x)))
lines(mx[, 2], predicty1, col="blue")
segments(mx[, 2], df[5:20, "uncertyn"], mx[, 2], df[5:20, "uncertyp"])
segments(mx[, 2]-1, df[5:20, "uncertyn"], mx[, 2]+1, df[5:20, "uncertyp"])
segments(mx[, 2]-1, df[5:20, "uncertyp"], mx[, 2]+1, df[5:20, "uncertyp"])
```



Vemos que se ajusta correctamente a la figura 1. Los parámetros son

```
model
```

```
##           [,1]
## [1,] 34.047728
## [2,]  2.239921
```

Y la varianza o incertidumbre en m sería

```
solve(t(mx) %*% solve(mstd2) %*% mx)
```


```
##           [,1]      [,2]
## [1,] 332.922601 -1.88954491
## [2,] -1.889545  0.01161663
```

## Ejercicio 2

En este ejercicio se trata de reproducir el ejercicio 1 pero tomando todos los puntos.

```
mx <- cbind(x^0, x) # matriz de diseño
my <- matrix(df[1:20,"y"], ncol=1,nrow=20) # variable objetivo
model <- model <- solve(t(mx) %*% solve(mstd1) %*% mx) %*% t(mx) %*% solve(mstd1) %*% my
predicty1 <- mx %*% model
```

```
plot(mx[,2], my[,1], xlim = c(0,max(x)))
lines(mx[,2], predicty1, col="blue")
segments(mx[,2], df[1:20,"uncertyn"], mx[,2], df[1:20, "uncertyp"])
segments(mx[,2]-1, df[1:20,"uncertyn"], mx[,2]+1, df[1:20, "uncertyn"])
segments(mx[,2]-1, df[1:20,"uncertyp"], mx[,2]+1, df[1:20, "uncertyp"])
```



Se ve que en este caso, al incluir los nuevos puntos el ajuste es mucho peor.

```
model
```

```
##           [,1]
## 213.273492
## x    1.076748
```

Y la varianza o incertidumbre en m sería

```
solve(t(mx) %*% solve(mstd1) %*% mx)
```

```
##           x
## 207.188189 -1.05427206
## x  -1.054272  0.00599181
```


### Ejercicio 3

En este caso se trata de usar una forma cuadrática de la expresión ignorando los primeros puntos al igual que en el ejercicio 1.

```

nx <- seq(from=0,to=300, length.out=100)
mx <- cbind(rep(1,16),df[5:20,"x"], df[5:20,"x"]^2) # matriz de diseño
nmx <- cbind(nx^0, nx, nx^2) # nueva, sobre la que se usará el modelo
my <- matrix(df[5:20,"y"], ncol=1,nrow=16) # variable objetivo
model <- solve(t(mnx) %*% solve(mstd2) %*% mx) %*% (t(mnx) %*% solve(mstd2) %*% my)
predicty1 <- nmx %*% model
plot(mx[,2], my[,1], xlim = c(0,max(x)))
lines(nx, predicty1, col="blue")
segments(mx[,2], df[5:20,"uncertyn"], mx[,2], df[5:20, "uncertyn"])
segments(mx[,2]-1, df[5:20,"uncertyn"], mx[,2]+1, df[5:20, "uncertyn"])
segments(mx[,2]-1, df[5:20,"uncertyp"], mx[,2]+1, df[5:20, "uncertyp"])

```



Y los parámetros  $W_{ML}$

```
model
```

```

##           [,1]
## [1,] 72.894626472
## [2,]  1.596050452
## [3,]  0.002298888

```

## Ejercicio 4

Tomamos la expresión de partida para la log-verosimilitud de los datos dado el parámetro del modelo

$$\frac{1}{2T} \sum^N (y_i - \mu)^2$$

derivando e igualando a 0

$$0 = \frac{1}{T} \left( \sum y_i - \sum \mu \right)$$

$$\begin{aligned} \frac{1}{T} \sum y_i &= \frac{1}{T} N \mu \\ \frac{1}{N} \sum y_i &= \mu_{ML} \end{aligned}$$

## Ejercicio 5

Tomar  $(Y - AX)^T(Y - AX)$  (7 en Hogg fitting) y demostrar, derivando, que  $X = [A^T C^{-1} A]^{-1} [A^T C^{-1} Y]$

### Solución

Este ejercicio es igual al 3.3 de PRML de Bishop.

$$\frac{1}{2} \sum^N r_i (t_i - w^T \phi(x_i))^2$$

derivando para obtener el gradiente, tal como en 3.13 de Bishop

$$\sum r_i (t_i - w^T \phi(x_i)) \phi(x_i)^T$$

igualando a 0 y reordenando

$$0 = \sum r_i t_i \phi(x_i)^T - w^T \left( \sum r_i \phi(x_i) \phi(x_i)^T \right)$$

que podemos expresarlo (resolviendo para w), si definimos  $r_i$  = cada elemento de la diagonal de  $C^{-1}$  como

$$(\Phi^T C^{-1} \Phi)^{-1} (\Phi C^{-1} t)$$

Para demostrarlo basta con reordenar

$$\begin{aligned} & \sum r_i t_i \phi(x_i)^T - w^T \left( \sum r_i \phi(x_i) \phi(x_i)^T \right) \\ &= \underbrace{\sum_i r_i t_i \phi(x_i)^T}_{\Phi^T C^{-1} t} \underbrace{\left( \sum_i r_i \phi(x_i) \phi(x_i)^T \right)^{-1}}_{(\Phi^T C^{-1} \Phi)^{-1}} = w^T \end{aligned}$$

haciendo la traspuesta ya tenemos el resultado final.